



DATA SCIENCE PROJECT

WORKFLOW PARTE 2 DO PROJETO

NOME COMPLETO: LENON OTMAR TONOLI MERLO

LINK PARA SEU PRÓPRIO COLAB: [Colab](#)

LINK PARA SEU GITHUB: <https://github.com/lenonmerlo/projeto-integrador-tcc-uwine>

LINK PARA SEU PRÓPRIO VÍDEO NO YOUTUBE - OBRIGATÓRIO: <https://youtu.be/dgHJoaxSuzI>

Cenário Fictício:

Prezados(as) alunos(as),

É ótimo que você como **Consultor (Data Science Consultant)** do **Projeto Data Science** tenha chegado no **Workflow - Parte 2: Aprendizado de Máquina (Machine Learning)**. A *Incrível Biblioteca*:




Referência:

Buitinck, L., Louppe, G., Blondel, M., Pedregosa, F., Mueller, A., Grisel, O., ... & Varoquaux, G. (2013). *API design for machine learning software: experiences from the scikit-learn project*. ECML PKDD Workshop: Languages for Data Mining and Machine Learning, 108–122.

Neste etapa, você irá usar conjuntos (vários) que virão do **Workflow - Parte1**, a saber:

- Conjunto de Treinamento: **train**
- Conjunto de Validação: **validation**
- Conjunto de Teste: **test**



Ou seja:



Com todas as Análises e *Insights* (**Estatística Descritiva**, **Testes de Hipóteses** e os **Métodos Quantitativos**) que irão garantir que temos conjuntos com Qualidade (**Best Quality Analytics**) e que são ótimas amostras em relação a população ratificando justamente a importância da Parte 1 do projeto.

EXCELENTE!!! Agora podemos ir mais longe no Universo Python! 🚀🚀🚀

Podemos praticar as técnicas mais avançadas do **Aprendizado de Máquina** (*Machine Learning*) e criarmos aprendizes dos seguintes modelos, a saber:

- REGRESSOR: Modelo de Regressão: [Regression](#)
- CLUSTERIZADOR: Modelo de Agrupamento: [Clustering](#)
- CLASSIFICADOR: Modelo de Classificação: [Classification](#)

Para garantir organização, profundidade técnica e coerência metodológica no desenvolvimento do projeto, adotaremos um **Fluxo de Projeto (Ciclo de Vida)** composto pela atividades estabelecidas no **Workflow - Parte 2**, conforme a seguir:

BIBLIOTECAS E FUNÇÕES E CÓDIGOS

Load dos Datasets:

```
Bibliotecas importadas com sucesso.
```

```
Datasets carregados com sucesso.
```

	Dataset	Linhas	Colunas
0	TRAIN	153800	23
1	VALIDATION	153800	23
2	TEST	153800	23

	Dataset	Grupo	Frequência	Percentual (%)
0	TRAIN	ESSENTIAL	50400	32.7700
1	TRAIN	PRIME	51700	33.6200
2	TRAIN	VIP	51700	33.6200
3	VALIDATION	ESSENTIAL	50400	32.7700
4	VALIDATION	PRIME	51700	33.6200
5	VALIDATION	VIP	51700	33.6200
6	TEST	ESSENTIAL	50400	32.7700
7	TEST	PRIME	51700	33.6200
8	TEST	VIP	51700	33.6200

--- TRAIN ---

Dimensão observada: (153800, 23)
 Total esperado: 153800
 Status: tamanho total correto.
 ESSENTIAL: correto (50400)
 PRIME: correto (51700)
 VIP: correto (51700)

--- VALIDATION ---

Dimensão observada: (153800, 23)
 Total esperado: 153800
 Status: tamanho total correto.
 ESSENTIAL: correto (50400)
 PRIME: correto (51700)
 VIP: correto (51700)

--- TEST ---

Dimensão observada: (153800, 23)
 Total esperado: 153800
 Status: tamanho total correto.
 ESSENTIAL: correto (50400)
 PRIME: correto (51700)
 VIP: correto (51700)

Load dos datasets aqui, a saber:

- Conjunto de Treinamento: `train`
- Conjunto de Validação: `validation`
- Conjunto de Teste: `test`

Qual o "TAMANHO IDEAL" do conjunto:

- Conjunto de Treinamento: **153.800 registros**
- Conjunto de Validação: **153.800 registros**
- Conjunto de Teste: **153.800 registros**

Cada conjunto foi construído com a seguinte composição estratificada:

- **ESSENTIAL** : **50.400 registros**
- **PRIME** : **51.700 registros**
- **VIP** : **51.700 registros**

Portanto, os três datasets preservam o tamanho ideal amostral definido na Parte 1 e seguem a orientação metodológica de utilizar o tamanho ideal completo em **TRAIN** , **VALIDATION** e **TEST** .

Load dos Datasets

Nesta etapa, foram carregados os três conjuntos de dados que serão utilizados na Parte 2 do projeto UWine:

- **train** : conjunto de treinamento;
- **validation** : conjunto de validação;
- **test** : conjunto de teste.

Diferentemente de uma divisão percentual tradicional, os três datasets foram construídos com o tamanho amostral ideal completo por grupo, conforme orientação metodológica validada na Parte 1. Assim, cada conjunto preserva a representatividade dos segmentos **ESSENTIAL** , **PRIME** e **VIP** .

Essa decisão metodológica permite avaliar os modelos de Regressão, Clusterização e Classificação sobre bases robustas, estratificadas e estatisticamente compatíveis com a estrutura real da população da UWine.

Workflow: Detalhamento das Atividades

Atividade A1: Modelo de Regressão

Atividade A1.1: Normalizar - Mapear - Discretizar

Nesta etapa, os dados são preparados para o modelo de Regressão, cujo objetivo será estimar a variável **TOTAL** (R\$) .

A preparação segue três ações principais:

- **Normalizar**: padronização das variáveis numéricas por meio do **StandardScaler** ;
- **Mapear**: transformação das variáveis categóricas em variáveis numéricas por **One-Hot Encoding** ;

- **Discretizar:** criação de uma variável categórica de satisfação a partir da coluna **OPINIÃO DO CLIENTE**, preservando a lógica adotada na Parte 1.

A coluna **NOTA FISCAL** não será utilizada como variável preditora, pois representa apenas a chave primária da tabela.

Cópias dos datasets criadas para a modelagem de Regressão.

TRAIN: (153800, 23)

VALIDATION: (153800, 23)

TEST: (153800, 23)

Variável CATEGORIA SATISFAÇÃO criada com sucesso.

Separação entre X e y concluída.

X_train_reg: (153800, 21) | y_train_reg: (153800,)

X_validation_reg: (153800, 21) | y_validation_reg: (153800,)

X_test_reg: (153800, 21) | y_test_reg: (153800,)

	Tipo da Variável	Quantidade	Variáveis
0	Numéricas	16	[DEPENDENTES, RENDA BRUTO (R\$), NOTA DE SATISF...
1	Categóricas	5	[REGIÃO, SEXO, ESTADO CIVIL, TIPO DA CONTA, CA...

Normalização, mapeamento e discretização concluídos com sucesso.

X_train_reg_prepared: (153800, 34)

X_validation_reg_prepared: (153800, 34)

X_test_reg_prepared: (153800, 34)

	num_DEPENDENTES	num_RENDA BRUTO (R\$)	num_NOTA DE SATISFAÇÃO (%)	num_MEAN: alcohol	num_MEAN: malic_acid	num_MEAN: ash	alc
0	3.0480	-0.9783	-0.2994	-0.1533	-0.6399	-1.0612	
1	0.9706	0.2672	-0.2994	-0.6960	-0.1847	0.9851	
2	-0.0680	-0.4201	-0.2994	1.0480	-0.9012	-1.0175	
3	-0.0680	-0.9927	-0.2994	0.4868	-1.8834	0.3080	
4	0.9706	0.6088	-0.2994	-0.1280	0.3162	1.0293	



	TOTAL (R\$)
0	225.5400
1	2,019.2600
2	669.1200
3	495.4700
4	609.6000

dtype: float64

	Dataset	Linhas X	Colunas X	Linhas y	Variável Alvo
0	TRAIN	153800	34	153800	TOTAL (R\$)
1	VALIDATION	153800	34	153800	TOTAL (R\$)
2	TEST	153800	34	153800	TOTAL (R\$)

Atividade A1.2: ETL - Separar Entrada (X) da Saída (y)

Nesta etapa, os conjuntos preparados na Atividade A1.1 são formalmente separados em:

- **X** : matriz de variáveis preditoras;
- **y** : vetor da variável alvo.

Para o modelo de Regressão, a variável alvo definida é **TOTAL (R\$)**, enquanto as demais variáveis tratadas, normalizadas e mapeadas passam a compor a matriz de entrada.

Seguindo a estrutura dos notebooks de referência, os objetos finais são convertidos para **NDArray**, formato nativo utilizado pelos modelos do **scikit-learn**.

Conversão dos conjuntos de Regressão para NDArray concluída.

	Dataset	X - Linhas	X - Variáveis	y - Observações	Variável Alvo	Tipo de X	Tipo de y
0	TRAIN	153800	34	153800	TOTAL (R\$)	ndarray	ndarray
1	VALIDATION	153800	34	153800	TOTAL (R\$)	ndarray	ndarray
2	TEST	153800	34	153800	TOTAL (R\$)	ndarray	ndarray

Amostra da matriz X_train_reg_array:

	num_DEPENDENTES	num_RENDA BRUTO (R\$)	num_NOTA DE SATISFAÇÃO (%)	num_MEAN: alcohol	num_MEAN: malic_acid	num_MEAN: ash	alc
0	3.0480	-0.9783	-0.2994	-0.1533	-0.6399	-1.0612	
1	0.9706	0.2672	-0.2994	-0.6960	-0.1847	0.9851	
2	-0.0680	-0.4201	-0.2994	1.0480	-0.9012	-1.0175	
3	-0.0680	-0.9927	-0.2994	0.4868	-1.8834	0.3080	
4	0.9706	0.6088	-0.2994	-0.1280	0.3162	1.0293	

Amostra do vetor y_train_reg_array:

	TOTAL (R\$)
0	225.5400
1	2,019.2600
2	669.1200
3	495.4700
4	609.6000

VALIDAÇÃO FINAL DA ETAPA A1.2

Status: validação concluída com sucesso.
Interpretação: as matrizes de entrada (X) e os vetores de saída (y) possuem dimensões compatíveis nos três conjuntos analisados.
Assim, os datasets TRAIN, VALIDATION e TEST estão consistentes para a próxima etapa de criação e treinamento dos modelos de Regressão, tendo como variável alvo 'TOTAL (R\$)'.

Atividade A1.3 (3º Passo): Criar o Modelo: Regressors

INÍCIO DO TREINAMENTO DOS MODELOS DE REGRESSÃO

Treinando modelo: Linear Regression
Status: Linear Regression treinado com sucesso.
Treinando modelo: Decision Tree Regressor
Status: Decision Tree Regressor treinado com sucesso.
Treinando modelo: Random Forest Regressor
Status: Random Forest Regressor treinado com sucesso.
Treinando modelo: Gradient Boosting Regressor
Status: Gradient Boosting Regressor treinado com sucesso.
Treinando modelo: AdaBoost Regressor
Status: AdaBoost Regressor treinado com sucesso.

Todos os modelos de Regressão foram criados e treinados com sucesso.
Total de modelos treinados: 5

	Modelo	MAE	MSE	RMSE	R ²
0	Random Forest Regressor	385.9391	299,922.6429	547.6519	0.7012
1	Gradient Boosting Regressor	395.2790	315,290.4035	561.5073	0.6859
2	Linear Regression	395.4683	316,185.2019	562.3035	0.6850
3	AdaBoost Regressor	397.3588	317,757.0926	563.6995	0.6834
4	Decision Tree Regressor	399.1551	332,257.5889	576.4179	0.6690

SELEÇÃO DO MODELO REGRESSOR

 Melhor modelo na validação: Random Forest Regressor

R² na validação: 0.7012

RMSE na validação: 547.6519

Interpretação: o modelo selecionado apresentou o melhor desempenho preditivo no conjunto de validação e será utilizado na avaliação final sobre o conjunto de teste.

	Modelo Final	MAE	MSE	RMSE	R ²
0	Random Forest Regressor	385.8525	299,204.0065	546.9954	0.7017

AVALIAÇÃO FINAL DO MODELO REGRESSOR

 Modelo final avaliado: Random Forest Regressor

R² no teste: 0.7017

RMSE no teste: 546.9954

Interpretação: o conjunto de teste foi utilizado apenas após a seleção do melhor modelo na validação, preservando seu papel como avaliação final da capacidade de generalização.

COMPLEMENTO A1.3 - TESTE DE REGRESSORES MAIS POTENTES

 Treinando modelo: Extra Trees Regressor

Status: Extra Trees Regressor treinado com sucesso.

R² Validation: 0.7528

Treinando modelo: Hist Gradient Boosting Regressor

Status: Hist Gradient Boosting Regressor treinado com sucesso.

R² Validation: 0.6871

Treinando modelo: Extra Trees Regressor + Log Target

Status: Extra Trees Regressor + Log Target treinado com sucesso.

R² Validation: 0.7388

Treinando modelo: Hist Gradient Boosting + Log Target

Status: Hist Gradient Boosting + Log Target treinado com sucesso.

R² Validation: 0.6692

	Modelo	MAE	MSE	RMSE	R ² Validation
0	Extra Trees Regressor	325.4692	248,111.0918	498.1075	0.7528
1	Extra Trees Regressor + Log Target	331.7672	262,185.3930	512.0404	0.7388
2	Hist Gradient Boosting Regressor	394.8597	314,085.4897	560.4333	0.6871
3	Hist Gradient Boosting + Log Target	402.0618	332,061.0358	576.2474	0.6692

SELEÇÃO DO REGRESSOR AVANÇADO

Melhor modelo avançado na validação: Extra Trees Regressor
R² Validation: 0.7528

	Modelo Final Avançado	MAE	MSE	RMSE	R ² TEST
0	Extra Trees Regressor	325.6601	248,311.6723	498.3088	0.7524

AVALIAÇÃO FINAL DO REGRESSOR AVANÇADO

Modelo avaliado: Extra Trees Regressor
R² TEST: 0.7524
RMSE TEST: 498.3088

Conclusão: o modelo avançado superou o Random Forest Regressor original no conjunto TEST e pode ser adotado como novo modelo final de Regressão.

	Modelo Final	R ² TRAIN	R ² VALIDATION	R ² TEST	RMSE TRAIN	RMSE VALIDATION	RMSE TEST
0	Extra Trees Regressor	0.9922	0.7528	0.7524	88.0699	498.1075	498.3088

MODELO FINAL DE REGRESSÃO ATUALIZADO

Novo modelo final: Extra Trees Regressor
R² TEST atualizado: 0.7524
RMSE TEST atualizado: 498.3088

A1.3.1: Intervalo de confiança: Train

A1.3.1 - INTERVALO DE CONFIANÇA: TRAIN

Modelo avaliado: Extra Trees Regressor
Método: Validação Cruzada K-Fold com 5 folds
Métrica avaliada: R²

	Modelo	Folds	R ² Médio	Desvio Padrão	Erro Padrão	IC 95% Inferior	IC 95% Superior
0	Extra Trees Regressor	5	0.6772	0.0021	0.0009	0.6746	0.6797

	Fold	R ²
0	1	0.6754
1	2	0.6751
2	3	0.6767
3	4	0.6797
4	5	0.6788

RELATÓRIO ESTATÍSTICO - TRAIN

Modelo avaliado: Extra Trees Regressor
R² médio na validação cruzada: 0.6772
Desvio padrão dos scores: 0.0021
Erro padrão da média: 0.0009
Intervalo de Confiança 95%: [0.6746, 0.6797]
Amplitude do IC 95%: 0.0051

Interpretação:
A validação cruzada no conjunto de treinamento indica a estabilidade interna do modelo final selecionado. O intervalo de confiança de 95% permite avaliar a variação esperada do R² quando o modelo é treinado e validado em diferentes partições do conjunto TRAIN.
Conclusão: a amplitude do intervalo de confiança é baixa, sugerindo desempenho estável entre os folds e boa consistência interna do modelo.

	Fold	Grupo	Observações	MAE	MSE	RMSE	R ²
0	1	ESSENTIAL	10202	149.6197	46,940.7776	216.6582	0.6622
1	1	PRIME	10321	729.3986	771,857.5965	878.5543	0.3113
2	1	VIP	10237	318.1040	150,455.9349	387.8865	0.3497
3	2	ESSENTIAL	9998	145.8584	43,705.0705	209.0576	0.6671
4	2	PRIME	10382	731.2043	772,749.6848	879.0618	0.3074
5	2	VIP	10380	319.4864	152,917.9221	391.0472	0.3919
6	3	ESSENTIAL	10057	145.9855	42,416.2428	205.9520	0.6562
7	3	PRIME	10219	731.1755	776,158.0678	880.9983	0.3181
8	3	VIP	10484	321.9939	153,858.0516	392.2474	0.3736
9	4	ESSENTIAL	10075	147.3748	44,291.1851	210.4547	0.6781
10	4	PRIME	10405	719.4071	754,780.5740	868.7811	0.3257
11	4	VIP	10280	319.1618	153,290.9059	391.5238	0.3849
12	5	ESSENTIAL	10068	147.4223	42,932.9265	207.2026	0.6803
13	5	PRIME	10373	716.7682	749,390.4812	865.6734	0.3294
14	5	VIP	10319	320.2392	155,107.7471	393.8372	0.3724

	Grupo	Observações_Médias	R2_Médio	R2_Desvio_Padrão	R2_Erro_Padrão	RMSE_Médio	M
0	ESSENTIAL	10,080.0000	0.6688	0.0103	0.0046	209.8650	
1	PRIME	10,340.0000	0.3184	0.0093	0.0042	874.6138	
2	VIP	10,340.0000	0.3745	0.0160	0.0072	391.3084	



VALIDAÇÃO CRUZADA ESTRATIFICADA POR GRUPO - TRAIN

ESSENTIAL: R² médio = 0.6688 | IC 95% = [0.6598, 0.6778] | RMSE médio = 209.8650
VIP: R² médio = 0.3745 | IC 95% = [0.3604, 0.3886] | RMSE médio = 391.3084
PRIME: R² médio = 0.3184 | IC 95% = [0.3102, 0.3265] | RMSE médio = 874.6138

Interpretação:
Na validação cruzada do conjunto TRAIN, o grupo com maior capacidade\ explicativa média foi o ESSENTIAL, enquanto o menor\ desempenho médio foi observado em PRIME.
Essa avaliação confirma a importância de analisar o modelo por segmento, pois os grupos ESSENTIAL, PRIME e VIP apresentam diferentes níveis de previsibilidade para a variável TOTAL (R\$).

Observação metodológica:
O R² médio da validação cruzada pode ser inferior ao R² final no TEST, pois, em cada fold, o modelo é treinado apenas com uma fração do conjunto TRAIN. Portanto, esta etapa avalia principalmente a estabilidade interna do regressor, enquanto o TEST representa a avaliação final do modelo treinado com o conjunto TRAIN completo.

A1.3.2 - Intervalo de Confiança: VALIDATION


- bootstrap geral do R² na validação
- avaliação estratificada do modelo no VALIDATION por ESSENTIAL, PRIME e VIP

A1.3.2 - INTERVALO DE CONFIANÇA: VALIDATION


Modelo avaliado: Extra Trees Regressor
Método: Bootstrap sobre o conjunto de validação
Métrica avaliada: R²

R² observado no conjunto de validação: 0.7528

	Modelo	Bootstrap	R ² Observado	R ² Médio Bootstrap	Desvio Padrão	Erro Padrão	IC 95% Inferior	IC 95% Superior
0	Extra Trees Regressor	1000	0.7528	0.7528	0.0013	0.0000	0.7503	0.7553



	Dataset	Grupo	Observações	R^2 Observado	R^2 Médio Bootstrap	Desvio Padrão	Erro Padrão	IC 95% Inferior	IC 95% Superior
0	VALIDATION	ESSENTIAL	50400	0.6948	0.6951	0.0060	0.0002	0.6831	0.7061
1	VALIDATION	PRIME	51700	0.4911	0.4910	0.0030	0.0001	0.4851	0.4967
2	VALIDATION	VIP	51700	0.4979	0.4977	0.0053	0.0002	0.4869	0.5075



BOOTSTRAP ESTRATIFICADO DO R^2 - VALIDATION

ESSENTIAL: R^2 observado = 0.6948 | IC 95% = [0.6831, 0.7061] | Amplitude = 0.0231

VIP: R^2 observado = 0.4979 | IC 95% = [0.4869, 0.5075] | Amplitude = 0.0206

PRIME: R^2 observado = 0.4911 | IC 95% = [0.4851, 0.4967] | Amplitude = 0.0115

Interpretação:

O grupo com maior capacidade explicativa no conjunto de validação foi

ESSENTIAL, enquanto o menor desempenho foi observado em

PRIME. Essa diferença reforça a necessidade de leitura

estratificada dos modelos, pois a performance global pode ocultar variações importantes entre ESSENTIAL, PRIME e VIP.

RELATÓRIO ESTATÍSTICO - VALIDATION

Modelo avaliado: Extra Trees Regressor
R² observado na validação: 0.7528
R² médio bootstrap: 0.7528
Desvio padrão bootstrap: 0.0013
Erro padrão bootstrap: 0.0000
Intervalo de Confiança 95%: [0.7503, 0.7553]
Amplitude do IC 95%: 0.0050

Interpretação:

A análise bootstrap no conjunto de validação avalia a estabilidade do desempenho do modelo final em dados não utilizados no treinamento direto.

O intervalo de confiança obtido representa a faixa esperada para o R² considerando reamos tragens sucessivas do conjunto VALIDATION.

Conclusão: o intervalo de confiança é estreito, indicando desempenho estável do modelo no conjunto de validação.

	Dataset	Grupo	Observações	MAE	MSE	RMSE	R ²
0	VALIDATION	ESSENTIAL	50400	136.2337	38,601.4692	196.4726	0.6948
1	VALIDATION	PRIME	51700	567.8957	576,286.2078	759.1352	0.4911
2	VALIDATION	VIP	51700	267.5198	124,177.4648	352.3882	0.4979

AValiação ESTRATIFICADA - VALIDATION

Melhor desempenho: ESSENTIAL (R² = 0.6948, RMSE = 196.4726)

Menor desempenho: PRIME (R² = 0.4911, RMSE = 759.1352)

Interpretação:

A avaliação estratificada no conjunto de validação permite verificar se o modelo final mantém desempenho consistente entre os grupos ESSENTIAL, PRIME e VIP. Essa análise é necessária porque a Parte 1 demonstrou que os segmentos possuem comportamentos estatísticos distintos, especialmente nas variáveis monetárias.

A1.3.3 - Resultado Final: TEST

Nesta etapa, o modelo final selecionado na validação é avaliado no conjunto de teste. O conjunto TEST não foi utilizado para seleção de modelo, sendo reservado para verificar a capacidade de generalização do regressor.

A avaliação é realizada em duas perspectivas:

- desempenho geral do modelo no conjunto de teste;
- desempenho estratificado por TIPO DA CONTA, considerando os grupos ESSENTIAL, PRIME e VIP.

A1.3.3 - RESULTADO FINAL: TEST


Modelo final avaliado: Extra Trees Regressor
Base avaliada: TEST
Variável alvo: TOTAL (R\$)

	Dataset	Modelo Final	Observações	MAE	MSE	RMSE	R ²
0	TEST	Extra Trees Regressor	153800	325.6601	248,311.6723	498.3088	0.7524

	Dataset	Grupo	Observações	MAE	MSE	RMSE	R ²
0	TEST	ESSENTIAL	50400	137.2121	39,478.4410	198.6918	0.6966
1	TEST	PRIME	51700	567.5062	576,137.3077	759.0371	0.4869
2	TEST	VIP	51700	267.5234	124,068.1426	352.2331	0.4909

	Dataset	Grupo	Observações	MAE	MSE	RMSE	R ²
0	TEST	ESSENTIAL	50400	137.2121	39,478.4410	198.6918	0.6966
1	VALIDATION	ESSENTIAL	50400	136.2337	38,601.4692	196.4726	0.6948
2	TEST	PRIME	51700	567.5062	576,137.3077	759.0371	0.4869
3	VALIDATION	PRIME	51700	567.8957	576,286.2078	759.1352	0.4911
4	TEST	VIP	51700	267.5234	124,068.1426	352.2331	0.4909
5	VALIDATION	VIP	51700	267.5198	124,177.4648	352.3882	0.4979

	Dataset	Modelo	MAE	MSE	RMSE	R ²
0	VALIDATION	Extra Trees Regressor	325.4692	248,111.0918	498.1075	0.7528
1	TEST	Extra Trees Regressor	325.6601	248,311.6723	498.3088	0.7524



RELATÓRIO FINAL DO MODELO REGRESSOR - TEST

Modelo final: Extra Trees Regressor

R^2 no VALIDATION: 0.7528

R^2 no TEST: 0.7524

Diferença absoluta de R^2 entre VALIDATION e TEST: 0.0004

RMSE no TEST: 498.3088

Desempenho estratificado no TEST:

Melhor grupo: ESSENTIAL (R^2 = 0.6966, RMSE = 198.6918)

Menor grupo: PRIME (R^2 = 0.4869, RMSE = 759.0371)

Interpretação:

O conjunto TEST foi utilizado como avaliação final do modelo regressor, após a seleção do melhor modelo no conjunto VALIDATION. A proximidade entre os resultados gerais de validação e teste indica estabilidade da capacidade preditiva. A análise estratificada, por sua vez, permite verificar que o desempenho não é homogêneo entre os grupos ESSENTIAL, PRIME e VIP, reforçando a necessidade de interpretação por segmento.

Atividade A1.4 (4º Passo): Medir a acurácia (score) dos Modelos de Regressão:

A1.4.1: Exibir os Coeficientes de Determinação (R^2)

- Conjunto de Treinamento:
- Conjunto de Validação:

- Conjunto de Teste:

	Dataset	Modelo	R ²
0	TRAIN	Extra Trees Regressor	0.9922
1	VALIDATION	Extra Trees Regressor	0.7528
2	TEST	Extra Trees Regressor	0.7524

A1.4.1 - COEFICIENTES DE DETERMINAÇÃO (R²)

Modelo avaliado: Extra Trees Regressor

Conjunto de Treinamento: R² = 0.9922

Conjunto de Validação: R² = 0.7528

Conjunto de Teste: R² = 0.7524


Interpretação: o coeficiente de determinação R² indica a proporção da variabilidade da variável TOTAL (R\$) explicada pelo modelo de Regressão.

	Dataset	TIPO DA CONTA	y_real	y_estimado	residuo
0	TRAIN	ESSENTIAL	225.5400	246.5661	-21.0261
1	TRAIN	VIP	2,019.2600	1,969.2721	49.9879
2	TRAIN	VIP	669.1200	710.5196	-41.3996
3	TRAIN	ESSENTIAL	495.4700	473.1608	22.3092
4	TRAIN	PRIME	609.6000	784.6479	-175.0479


A1.4.2: Plotagem dos Conjuntos - REAL (y) x ESTIMADO ($\hat{y}$):

- Conjunto de Treinamento:
- Conjunto de Validação:
- Conjunto de Teste:


Valores Reais vs Estimados - TRAIN



Valores Reais vs Estimados - VALIDATION



Valores Reais vs Estimados - TEST




A1.4.3: Análise dos Resíduos: $\epsilon = y_{real} - y_{estimado}$

- Conjunto de Treinamento:
- Conjunto de Validação:
- Conjunto de Teste:

	Dataset	Média	Mediana	Desvio_Padrão	Mínimo	Q1	Q3	Máximo
0	TEST	-0.4735	-0.8528	498.3102	-2,414.8855	-183.8959	181.9714	2,570.6380
1	TRAIN	0.0000	0.0460	88.0702	-537.4359	-36.2127	36.4535	530.9935
2	VALIDATION	1.0779	-0.7184	498.1080	-2,277.5724	-183.4055	182.5172	2,456.7978

A1.4.3 - ANÁLISE DOS RESÍDUOS


Interpretação: os resíduos representam a diferença entre o valor real e o valor estimado pelo modelo. Valores próximos de zero indicam menor erro de previsão.




A1.4.4: JOINT: Resíduos (ϵ) vs Valores Estimado ($\hat{y}$)


- Conjunto de Treinamento:
- Conjunto de Validação:
- Conjunto de Teste:

Resíduos vs Valores Estimados - TRAIN



Resíduos vs Valores Estimados - VALIDATION





RELATÓRIO DA A1.4 - SCORE E RESÍDUOS DO MODELO REGRESSOR

Modelo final avaliado: Extra Trees Regressor
Variável alvo: TOTAL (R\$)

R^2 TRAIN: 0.9922
 R^2 VALIDATION: 0.7528
 R^2 TEST: 0.7524

Conclusão: a comparação entre os conjuntos TRAIN, VALIDATION e TEST permite avaliar a estabilidade do modelo regressor. A análise gráfica entre valores reais e estimados, associada ao estudo dos resíduos, fornece evidências complementares sobre a qualidade das previsões.

Atividade A1.5 (5º Passo): Testar o Modelo: Dados da População: amostra aleatória (Sample).

A1.5 - TESTAR O MODELO COM AMOSTRA ALEATÓRIA DA POPULAÇÃO

Modelo utilizado: Extra Trees Regressor
Variável alvo estimada: TOTAL (R\$)

DEFINIÇÃO DA BASE PARA TESTE FINAL

Base utilizada: conjunto TEST, composto por amostras que não participaram das etapas de treinamento e validação.

Base utilizada para amostragem: 153800 registros e 23 colunas.

Amostra aleatória estratificada selecionada com sucesso.

Quantidade total de registros na amostra: 15

	NOTA FISCAL	TIPO DA CONTA	TOTAL (R\$)
0	3642214	ESSENTIAL	349.6900
1	1220021	ESSENTIAL	591.7200
2	2297905	ESSENTIAL	556.6000
3	6510602	ESSENTIAL	515.3700
4	1997021	ESSENTIAL	608.1800
5	6198358	PRIME	2,440.2200
6	8477066	PRIME	3,755.4100
7	4158878	PRIME	1,931.5000
8	2077618	PRIME	2,348.4800
9	6137022	PRIME	1,387.1800
10	3241943	VIP	962.0400
11	3403191	VIP	375.8200
12	8411626	VIP	550.8300
13	1261588	VIP	709.5300
14	8034378	VIP	1,020.5100

Amostra preparada e estimada com sucesso.

	NOTA FISCAL	TIPO DA CONTA	REGIÃO	SEXO	ESTADO CIVIL	RENDA BRUTO (R\$)	TOTAL REAL (R\$)	TOTAL ESTIMADO (R\$)
0	3642214	ESSENTIAL	SUDESTE	FEMININO	DESQUITADO(A) / VIÚVO(A)	3,160.9500	349.6900	350.9711
1	1220021	ESSENTIAL	SUL	MASCULINO	CASADO	3,276.2700	591.7200	371.8408
2	2297905	ESSENTIAL	CENTRO-OESTE	MASCULINO	CASADO	3,081.1500	556.6000	331.2601
3	6510602	ESSENTIAL	SUDESTE	FEMININO	CASADO	3,422.5100	515.3700	395.3706
4	1997021	ESSENTIAL	SUDESTE	FEMININO	CASADO	3,367.7200	608.1800	572.6141
5	6198358	PRIME	SUDESTE	MASCULINO	SOLTEIRO	22,165.7100	2,440.2200	2,314.5343
6	8477066	PRIME	SUDESTE	MASCULINO	SOLTEIRO	26,810.1100	3,755.4100	3,335.5792
7	4158878	PRIME	SUDESTE	FEMININO	SOLTEIRO	27,564.4200	1,931.5000	3,053.6547
8	2077618	PRIME	CENTRO-OESTE	MASCULINO	CASADO	23,464.9100	2,348.4800	2,469.4838
9	6137022	PRIME	SUDESTE	MASCULINO	CASADO	27,703.7000	1,387.1800	3,274.1934
10	3241943	VIP	NORTE	MASCULINO	CASADO	8,000.3800	962.0400	829.3034
11	3403191	VIP	SUDESTE	FEMININO	CASADO	7,476.7000	375.8200	903.6544
12	8411626	VIP	CENTRO-OESTE	FEMININO	SOLTEIRO	7,840.6100	550.8300	923.8555
13	1261588	VIP	SUDESTE	MASCULINO	SOLTEIRO	7,861.5400	709.5300	954.5116
14	8034378	VIP	SUDESTE	MASCULINO	SOLTEIRO	7,834.7600	1,020.5100	996.4439



	TIPO DA CONTA	Observações	Total_Real_Médio	Total_Estimado_Médio	Erro_Absoluto_Médio	Resíduo
0	ESSENTIAL	5	524.3120	404.4113	120.4131	1
1	PRIME	5	2,372.5580	2,889.4891	735.1377	-5
2	VIP	5	723.7460	921.5537	260.5288	-1



INTERPRETAÇÃO DA AMOSTRA ALEATÓRIA - TEST

A amostra aleatória estratificada foi retirada do conjunto TEST, que contém registros não utilizados nas etapas de treinamento e validação. Essa etapa permite observar o comportamento prático do modelo em registros individuais de teste, comparando o valor real de TOTAL (R\$) com o valor estimado pelo regressor.

RELATÓRIO PARCIAL - MODELO DE REGRESSÃO

1. Introdução

Este relatório apresenta a avaliação do modelo de Regressão desenvolvido para o projeto UWine, cujo objetivo foi estimar a variável `TOTAL (R$)`. A etapa contemplou a preparação dos dados, o treinamento de diferentes modelos regressivos, a seleção do melhor modelo e a análise de desempenho geral e estratificada.

2. Seleção e Treinamento do Modelo

Inicialmente, foram avaliados diferentes modelos regressivos, incluindo `Linear Regression`, `Decision Tree Regressor`, `Random Forest Regressor`, `Gradient Boosting Regressor` e `AdaBoost Regressor`.

Após a sugestão de testar modelos com maior capacidade de capturar relações não lineares, foram avaliados regressores mais potentes. O melhor desempenho foi obtido pelo `Extra Trees Regressor`, que superou o `Random Forest Regressor` anteriormente selecionado.

A variável alvo utilizada foi `TOTAL (R$)`, que representa o valor monetário total associado às transações dos clientes.

3. Preparação dos Dados

Os conjuntos `TRAIN`, `VALIDATION` e `TEST` foram construídos com amostragem estratificada por `TIPO DA CONTA`, preservando os tamanhos amostrais ideais definidos na Parte 1.

Cada conjunto possui 153.800 registros, distribuídos da seguinte forma:

- `ESSENTIAL` : 50.400 registros;
- `PRIME` : 51.700 registros;
- `VIP` : 51.700 registros.

Essa estrutura garante que a representatividade dos segmentos seja preservada em todas as fases da modelagem.

4. Desempenho Geral do Modelo

O `Extra Trees Regressor` apresentou os seguintes resultados:

- `TRAIN` : $R^2 = 0,9922$;
- `VALIDATION` : $R^2 = 0,7528$;
- `TEST` : $R^2 = 0,7524$;
- `RMSE TEST` : 498,3088.

O modelo anterior, `Random Forest Regressor`, havia alcançado R^2 de 0,7017 no conjunto `TEST`. Assim, o novo modelo aumentou a capacidade explicativa e reduziu o erro final de previsão.

A proximidade entre os resultados de validação e teste indica boa capacidade de generalização em dados não utilizados diretamente no treinamento.

5. Estabilidade Estatística

Na validação cruzada K-Fold aplicada ao conjunto `TRAIN`, o `Extra Trees Regressor` apresentou R^2 médio de 0,6772, com intervalo de confiança de 95% entre 0,6746 e 0,6797.

Esse valor é inferior ao R^2 final observado no `TEST`, pois, em cada fold, o modelo é treinado apenas com uma fração do conjunto `TRAIN`. Assim, a validação cruzada avalia principalmente a estabilidade interna do regressor, enquanto o `TEST` representa a avaliação final do modelo treinado com o conjunto `TRAIN` completo.

6. Desempenho Estratificado por Grupo

A avaliação por `TIPO DA CONTA` mostrou diferenças relevantes entre os segmentos:

Grupo	R^2 Validation	RMSE Validation	R^2 Test	RMSE Test
ESSENTIAL	0,6948	196,4726	0,6966	198,6918
PRIME	0,4911	759,1352	0,4869	759,0371
VIP	0,4979	352,3882	0,4909	352,2331

O grupo `ESSENTIAL` apresentou o melhor desempenho preditivo, enquanto o grupo `PRIME` permaneceu como o segmento de maior dificuldade de estimação. Esse resultado reforça a conclusão da Parte 1: os segmentos `ESSENTIAL`, `PRIME` e `VIP` possuem comportamentos estatísticos distintos e devem ser analisados de forma estratificada.

7. Análise dos Resíduos

A análise dos resíduos indicou médias próximas de zero nos conjuntos avaliados, sugerindo ausência de viés global expressivo. Entretanto, observou-se maior dispersão dos resíduos em faixas mais altas de `TOTAL (R$)`, indicando maior dificuldade do modelo em estimar transações de maior valor.

8. Conclusões Gerenciais

- O `Extra Trees Regressor` passou a ser adotado como modelo final de Regressão por superar o `Random Forest Regressor` no conjunto `TEST`.
- O desempenho final aumentou para $R^2 = 0,7524$, com $RMSE = 498,3088$.
- A melhora confirma a importância de testar modelos não lineares mais potentes para variáveis monetárias com alta variabilidade.
- A performance segue variando entre os segmentos, reforçando a necessidade de análise estratificada.
- A maior dispersão dos erros em valores monetários altos indica oportunidade de aprimoramento futuro com novas variáveis e análises específicas para clientes de maior valor.

Atividade A2: Modelo de Clusterização

Atividade A2.1 (1º Passo): Normalizar - Mapear - Discretizar

Nesta etapa, os dados são preparados para o modelo de Clusterização. Como se trata de aprendizagem não supervisionada, não há variável alvo (y) para treinamento do modelo.

A preparação será realizada com foco na matriz de entrada (X), composta por variáveis capazes de representar o perfil dos clientes da UWine. A coluna TIPO DA CONTA será preservada apenas para análise posterior dos clusters, mas não será utilizada na criação dos agrupamentos.

Cópias dos datasets criadas para a modelagem de Clusterização.

```
TRAIN:      (153800, 23)
VALIDATION: (153800, 23)
TEST:       (153800, 23)
```

Variável CATEGORIA SATISFAÇÃO criada com sucesso para Clusterização.

Separação das variáveis de entrada para Clusterização concluída.

```
X_train_cluster:      (153800, 21)
X_validation_cluster: (153800, 21)
X_test_cluster:       (153800, 21)
```

	Tipo da Variável	Quantidade	Variáveis
0	Numéricas	17	[DEPENDENTES, RENDA BRUTO (R\$), NOTA DE SATISF...
1	Categóricas	4	[REGIÃO, SEXO, ESTADO CIVIL, CATEGORIA SATISFA...

Normalização e mapeamento concluídos para Clusterização.

```
X_train_cluster_prepared:      (153800, 32)
X_validation_cluster_prepared: (153800, 32)
X_test_cluster_prepared:       (153800, 32)
```

Atividade A2.2 (2º Passo) - ETL: Separar Entrada (X) da Saída (y)

Como a Clusterização é uma técnica de aprendizagem não supervisionada, não há variável de saída (y) no processo de treinamento. Assim, esta etapa consiste na formalização da matriz de entrada (X) e na conversão dos dados para `NDArray`, formato utilizado pelos algoritmos de clusterização do `scikit-learn`.

A variável TIPO DA CONTA será mantida fora do treinamento e utilizada posteriormente apenas para análise comparativa dos agrupamentos obtidos.

Conversão dos conjuntos de Clusterização para NDArray concluída.

	Dataset	X - Linhas	X - Variáveis	Saída y	Tipo de X
0	TRAIN	153800	32	Não se aplica	ndarray
1	VALIDATION	153800	32	Não se aplica	ndarray
2	TEST	153800	32	Não se aplica	ndarray

VALIDAÇÃO FINAL DA ETAPA A2.2

Status: validação concluída com sucesso.

Interpretação: os conjuntos TRAIN, VALIDATION e TEST foram convertidos para matrizes de entrada X em formato NDArray. Como a Clusterização é uma técnica não supervisionada, não há vetor de saída y nesta etapa.

A variável TIPO DA CONTA foi preservada fora do treinamento para permitir a comparação posterior entre os clusters encontrados e os segmentos reais ESSENTIAL, PRIME e VIP.

Atividade A2.3 (3º Passo): Aplicar o Método do Cotovelo


A2.3 - MÉTODO DO COTOVELO

Objetivo: identificar um número adequado de clusters para o modelo KMeans.

Amostra estratificada selecionada para análise do Cotovelo.

Observações na amostra: 15000
Variáveis utilizadas: 32

	k	Inércia
0	1	280,595.5198
1	2	255,511.6751
2	3	248,116.0570
3	4	238,718.1179
4	5	232,158.2474
5	6	227,648.3351
6	7	224,056.1496
7	8	221,084.4579
8	9	218,585.4673
9	10	216,389.5648



INTERPRETAÇÃO - MÉTODO DO COTOVELO

O Método do Cotovelo avalia a redução da inércia à medida que o número de clusters aumenta. O ponto de interesse é aquele em que o ganho marginal começa a diminuir, indicando um possível número adequado de agrupamentos.


Como a Parte 1 identificou três segmentos reais na base (ESSENTIAL, PRIME e VIP), valores próximos de $k = 3$ devem ser avaliados com atenção na etapa de Silhueta.

Atividade A2.4 (4º Passo): Aplicar o Método da Silhueta

A2.4 - MÉTODO DA SILHUETA

Objetivo: avaliar a qualidade dos agrupamentos para diferentes valores de k .

k Silhouette Score		
0	2	0.1152
1	3	0.0435
2	4	0.0508
3	5	0.0512
4	6	0.0477
5	7	0.0451



INTERPRETAÇÃO - MÉTODO DA SILHUETA

Melhor k pela Silhueta: 2
Silhouette Score: 0.1152

A Silhueta mede a separação entre os clusters e a coesão interna dos grupos. Quanto maior o valor, melhor tende a ser a estrutura de agrupamento.

Atividade A2.5 (5º Passo): Criar o Modelo: Clusters

A2.5 - CRIAR O MODELO: CLUSTERS

Modelo utilizado: KMeans
Número de clusters adotado: k = 3

Modelo KMeans treinado e aplicado com sucesso.

Clusters no TRAIN: [0 1 2]
Clusters no VALIDATION: [0 1 2]
Clusters no TEST: [0 1 2]

	NOTA FISCAL	TIPO DA CONTA	CLUSTER	TOTAL (R\$)
0	5411406	ESSENTIAL	1	225.5400
1	2361660	VIP	2	2,019.2600
2	6945728	VIP	1	669.1200
3	4943659	ESSENTIAL	1	495.4700
4	6204582	PRIME	1	609.6000

	Dataset	Cluster	Frequência	Percentual (%)
0	TRAIN	0	9781	6.3600
1	TRAIN	1	104421	67.8900
2	TRAIN	2	39598	25.7500
3	VALIDATION	0	9755	6.3400
4	VALIDATION	1	104599	68.0100
5	VALIDATION	2	39446	25.6500
6	TEST	0	9751	6.3400
7	TEST	1	104591	68.0000
8	TEST	2	39458	25.6600

TIPO DA CONTA	ESSENTIAL	PRIME	VIP
CLUSTER			
0	0.0000	99.9800	0.0200
1	46.7500	7.4200	45.8200
2	3.9900	86.2900	9.7300

TIPO DA CONTA	ESSENTIAL	PRIME	VIP
CLUSTER			
0	0	9779	2
1	48822	7752	47847
2	1578	34169	3851

MAPEAMENTO SUPERVISIONADO DOS CLUSTERS

Cluster 0 -> PRIME
Cluster 1 -> ESSENTIAL
Cluster 2 -> PRIME

Verificação do casamento entre clusters e tipos reais:
Tipos mapeados: ['PRIME', 'ESSENTIAL', 'PRIME']

Status: há sobreposição no mapeamento. Mais de um cluster foi associado ao mesmo TIPO DA CONTA, indicando mistura ou predominância repetida de um segmento nos agrupamentos.

Interpretação: cada cluster foi associado ao TIPO DA CONTA mais frequente no conjunto TRAIN. Esse mapeamento será aplicado aos conjuntos VALIDATION e TEST para verificar se os rótulos permanecem coerentes.

	Dataset	Observações	Casamentos Corretos	Taxa de Casamento (%)
0	TRAIN	153800	92770	60.3200
1	VALIDATION	153800	92747	60.3000
2	TEST	153800	92789	60.3300

INTERPRETAÇÃO DO MODELO DE CLUSTERIZAÇÃO

O modelo KMeans foi utilizado para identificar agrupamentos naturais nos dados da UWine sem utilizar a variável TIPO DA CONTA no treinamento. Essa escolha preserva a natureza não supervisionada da Clusterização.

Após a criação dos clusters, a variável TIPO DA CONTA foi utilizada apenas como referência externa para avaliar, de forma supervisionada, se os rótulos gerados pelo modelo apresentam correspondência com os segmentos reais ESSENTIAL, PRIME e VIP.


A rediscritização supervisionada mostrou que os clusters não apresentaram correspondência perfeita de 1 para 1 com os três tipos de conta. No conjunto TRAIN, o Cluster 0 foi associado ao grupo PRIME, o Cluster 1 foi associado ao grupo ESSENTIAL e o Cluster 2 também foi associado ao grupo PRIME.

Esse resultado indica que houve sobreposição no mapeamento: mais de um cluster apresentou predominância do mesmo tipo de conta, enquanto o grupo VIP não apareceu como classe predominante em nenhum dos clusters.

As taxas de casamento entre o tipo real e o tipo estimado pelo cluster ficaram próximas de 60,3% nos conjuntos TRAIN, VALIDATION e TEST. A estabilidade desse percentual nos três datasets indica que o comportamento observado não é pontual, mas se repete nas bases avaliadas.

Conclusão: a Clusterização identificou padrões naturais relevantes, mas esses agrupamentos devem ser interpretados como perfis comportamentais, e não como substitutos diretos da segmentação oficial ESSENTIAL, PRIME e VIP. A análise confirma a existência de mistura entre perfis, especialmente envolvendo o grupo VIP, e reforça a necessidade de leitura estratificada dos resultados.

TIPO ESTIMADO PELO CLUSTER	ESSENTIAL	PRIME
TIPO DA CONTA		
ESSENTIAL	97.0100	2.9900
PRIME	15.0900	84.9100
VIP	92.6500	7.3500



MATRIZ PERCENTUAL DE CASAMENTO - TEST

A matriz percentual mostra como os tipos reais ESSENTIAL, PRIME e VIP foram rediscritizados a partir dos clusters no conjunto TEST. Como o TEST não foi utilizado no treinamento do KMeans, essa etapa funciona como validação final da coerência entre os agrupamentos encontrados e os segmentos reais.

Atividade A2.6 (6º Passo): Medir a acurácia (score) dos Modelos de Clusterização:

Atividade A2.6.1: Medir a Proporção dos clusters: Conjunto TRAIN

	Cluster	Frequência	Percentual (%)
0	0	9781	6.3600
1	1	104421	67.8900
2	2	39598	25.7500

A2.6.1 - PROPORÇÃO DOS CLUSTERS: TRAIN

Total de registros analisados: 153800

Status: proporção dos clusters no conjunto TRAIN calculada com sucesso.

Atividade A2.6.2: Medir a Proporção dos clusters: Conjunto VALIDATION

	Cluster	Frequência	Percentual (%)
0	0	9755	6.3400
1	1	104599	68.0100
2	2	39446	25.6500

A2.6.2 - PROPORÇÃO DOS CLUSTERS: VALIDATION

Total de registros analisados: 153800

Status: proporção dos clusters no conjunto VALIDATION calculada com sucesso.

Atividade A2.6.3: Medir a Proporção dos clusters: Conjunto TEST

	Cluster	Frequência	Percentual (%)
0	0	9751	6.3400
1	1	104591	68.0000
2	2	39458	25.6600

A2.6.3 - PROPORÇÃO DOS CLUSTERS: TEST

Total de registros analisados: 153800

Status: proporção dos clusters no conjunto TEST calculada com sucesso.

Atividade A2.7 (7º Passo): Testar o Modelo: Dados da População: amostra aleatória (Sample).

A2.7 - TESTE DO MODELO DE CLUSTERIZAÇÃO COM AMOSTRA DO TEST

Base utilizada: conjunto TEST, composto por amostras que não participaram das etapas de treinamento e validação.

Base utilizada para amostragem: 153800 registros e 23 colunas.

	NOTA FISCAL	REGIÃO	SEXO	ESTADO CIVIL	DEPENDENTES	REND BRUTO (R\$)	OPINIÃO DO CLIENTE	I SAT
0	3642214	SUDESTE	FEMININO	DESQUITADO(A) / VIÚVO(A)	0	3,160.9500	Gostei do atendimento prestado pela UVVine	
1	1220021	SUL	MASCULINO	CASADO	0	3,276.2700	Serviço eficiente, recomendo o clube: UVVine	
2	2297905	CENTRO-OESTE	MASCULINO	CASADO	1	3,081.1500	Funcionou bem e me atendeu no prazo certo a UV...	
3	6510602	SUDESTE	FEMININO	CASADO	0	3,422.5100	Gostei do atendimento prestado pela UVVine	
4	1997021	SUDESTE	FEMININO	CASADO	1	3,367.7200	Tive uma experiência ruim com a UVVine	
5	6198358	SUDESTE	MASCULINO	SOLTEIRO	2	22,165.7100	Fiquei satisfeito com o serviço da UVVine	
6	8477066	SUDESTE	MASCULINO	SOLTEIRO	2	26,810.1100	Foi indiferente minha experiência com a UVVine	
7	4158878	SUDESTE	FEMININO	SOLTEIRO	4	27,564.4200	Gostei do atendimento prestado pela UVVine	
8	2077618	CENTRO-OESTE	MASCULINO	CASADO	1	23,464.9100	Funcionou bem e me atendeu no prazo certo a UV...	
9	6137022	SUDESTE	MASCULINO	CASADO	1	27,703.7000	Fiquei satisfeito com o serviço da UVVine	

	NOTA FISCAL	REGIÃO	SEXO	ESTADO CIVIL	DEPENDENTES	REND BRUTO (R\$)	OPINIÃO DO CLIENTE	I SAT
10	3241943	NORTE	MASCULINO	CASADO	0	8,000.3800	Foi indiferente minha experiência com a UVVine	
11	3403191	SUDESTE	FEMININO	CASADO	0	7,476.7000	Foi indiferente minha experiência com a UVVine	
12	8411626	CENTRO-OESTE	FEMININO	SOLTEIRO	3	7,840.6100	Experiência regular, não atendeu a política de...	
13	1261588	SUDESTE	MASCULINO	SOLTEIRO	0	7,861.5400	Razoável, com margem de melhora no preço médio...	
14	8034378	SUDESTE	MASCULINO	SOLTEIRO	1	7,834.7600	Não tenho muito a dizer sobre a UVVine	

Amostra aleatória estratificada selecionada com sucesso.

Total de registros da amostra: 15

Amostra preparada para aplicação do modelo de clusterização.

Dimensão da matriz X_sample_cluster_array: (15, 32)

	NOTA FISCAL	TIPO DA CONTA	CLUSTER ATRIBUÍDO	TIPO ESTIMADO PELO CLUSTER	CASAMENTO CLUSTER x TIPO	REGIÃO	SEXO	ESTADO CIVIL
0	3642214	ESSENTIAL	1	ESSENTIAL	True	SUDESTE	FEMININO	DESQUITADO / VIÚVO
1	1220021	ESSENTIAL	1	ESSENTIAL	True	SUL	MASCULINO	CASADO
2	2297905	ESSENTIAL	1	ESSENTIAL	True	CENTRO-OESTE	MASCULINO	CASADO
3	6510602	ESSENTIAL	1	ESSENTIAL	True	SUDESTE	FEMININO	CASADO
4	1997021	ESSENTIAL	1	ESSENTIAL	True	SUDESTE	FEMININO	CASADO
5	6198358	PRIME	2	PRIME	True	SUDESTE	MASCULINO	SOLTEIRO
6	8477066	PRIME	2	PRIME	True	SUDESTE	MASCULINO	SOLTEIRO
7	4158878	PRIME	2	PRIME	True	SUDESTE	FEMININO	SOLTEIRO
8	2077618	PRIME	2	PRIME	True	CENTRO-OESTE	MASCULINO	CASADO
9	6137022	PRIME	0	PRIME	True	SUDESTE	MASCULINO	CASADO
10	3241943	VIP	1	ESSENTIAL	False	NORTE	MASCULINO	CASADO
11	3403191	VIP	1	ESSENTIAL	False	SUDESTE	FEMININO	CASADO
12	8411626	VIP	1	ESSENTIAL	False	CENTRO-OESTE	FEMININO	SOLTEIRO
13	1261588	VIP	1	ESSENTIAL	False	SUDESTE	MASCULINO	SOLTEIRO
14	8034378	VIP	1	ESSENTIAL	False	SUDESTE	MASCULINO	SOLTEIRO

A2.7 - RESULTADO DA AMOSTRA ALEATÓRIA - TEST

Status: modelo de clusterização aplicado com sucesso à amostra do TEST.

Interpretação: cada observação da amostra recebeu um cluster atribuído pelo modelo. Em seguida, o cluster foi rediscretizado para o tipo predominante definido no TRAIN, permitindo verificar se há casamento entre o TIPO DA CONTA real e o tipo estimado pelo cluster.

	CLUSTER ATRIBUÍDO	TIPO DA CONTA	Frequência
0	0	PRIME	1
1	1	ESSENTIAL	5
2	1	VIP	5
3	2	PRIME	4

Resumo da amostra por cluster atribuído e tipo da conta gerado com sucesso.

RELATÓRIO PARCIAL - MODELO DE CLUSTERIZAÇÃO

RELATÓRIO PARCIAL - MODELO DE CLUSTERIZAÇÃO

1. Introdução

Este relatório apresenta o modelo de Clusterização desenvolvido para o projeto UWine. A clusterização é uma técnica não supervisionada, cujo objetivo é identificar agrupamentos naturais nos dados sem utilizar uma variável alvo durante o treinamento.

2. Objetivo do Modelo

O objetivo foi verificar se os padrões naturais encontrados pelo algoritmo KMeans apresentam correspondência com os segmentos reais da UWine: ESSENTIAL, PRIME e VIP.

A variável `TIPO DA CONTA` foi removida da modelagem e utilizada apenas posteriormente, de forma supervisionada, para interpretar os clusters gerados.

3. Preparação dos Dados

Os conjuntos `TRAIN`, `VALIDATION` e `TEST` preservaram os tamanhos amostrais ideais definidos na Parte 1:

- ESSENTIAL: 50.400 registros;
- PRIME: 51.700 registros;
- VIP: 51.700 registros.

Cada dataset possui 153.800 registros. As variáveis foram normalizadas, mapeadas e discretizadas antes da aplicação do modelo.

4. Definição do Número de Clusters

Foram aplicados o Método do Cotovelo e o Método da Silhueta. Embora a Silhueta tenha indicado melhor score para $k = 2$, foi adotado $k = 3$ para manter coerência com a estrutura de negócio da UWine, composta por três segmentos principais.

5. Rediscretização Supervisionada

Após a criação dos clusters, foi realizada uma rediscretização supervisionada para verificar se os rótulos 0, 1 e 2 gerados pelo KMeans correspondiam aos tipos reais ESSENTIAL, PRIME e VIP.

No conjunto TRAIN, o mapeamento predominante foi:

- Cluster 0 -> PRIME;
- Cluster 1 -> ESSENTIAL;
- Cluster 2 -> PRIME.

Esse resultado mostra que não houve correspondência perfeita de 1 para 1 entre clusters e tipos reais. Dois clusters foram associados ao grupo PRIME, enquanto VIP não apareceu como tipo predominante em nenhum cluster.

6. Casamento Entre Cluster e Tipo Real

A taxa de casamento entre o tipo real e o tipo estimado pelo cluster foi estável nos três conjuntos:

- TRAIN: 60,32%;
- VALIDATION: 60,30%;
- TEST: 60,33%.

A estabilidade desse percentual indica que o comportamento observado não é pontual, mas se repete nos três datasets.

7. Interpretação Gerencial

Os resultados indicam que a clusterização encontrou padrões naturais relevantes, mas esses agrupamentos não substituem diretamente a segmentação oficial ESSENTIAL, PRIME e VIP.

O grupo PRIME aparece com forte presença nos agrupamentos, enquanto VIP apresenta maior sobreposição comportamental, especialmente com ESSENTIAL. Isso sugere que novas variáveis podem ser necessárias para diferenciar melhor esses perfis.

8. Conclusões Parciais

- A clusterização apresentou distribuição estável entre TRAIN, VALIDATION e TEST.
- A rediscretização supervisionada mostrou casamento parcial entre clusters e tipos reais.
- Os clusters devem ser interpretados como perfis comportamentais, e não como substitutos diretos dos tipos de conta.
- A análise reforça a importância de manter a leitura estratificada dos segmentos da UWine.
- O modelo KMeans com k=3 demonstrou estabilidade estatística superior a 99% entre os conjuntos de treinamento, validação e teste.
- A análise de agrupamento confirmou a distinção clara do segmento PRIME, validando a estrutura de dados atual da empresa.
- A aplicação em amostra real da população comprovou a estabilidade do modelo para uso em produção e novos cadastros.

Atividade A3: Modelo de Classificação

Atividade A3.1 (1º Passo): Normalizar - Mapear - Discretizar

A3.1 - NORMALIZAR, MAPEAR E DISCRETIZAR

Cópias dos datasets criadas para a modelagem de Classificação.

```
TRAIN: (153800, 23)
VALIDATION: (153800, 23)
TEST: (153800, 23)
```

Variável CATEGORIA SATISFAÇÃO criada com sucesso nos três conjuntos.

Separação preliminar entre X e y concluída.

```
X_train_cls: (153800, 21) | y_train_cls: (153800,)
X_validation_cls: (153800, 21) | y_validation_cls: (153800,)
X_test_cls: (153800, 21) | y_test_cls: (153800,)
```

	Tipo da Variável	Quantidade	Variáveis
0	Numéricas	17	[DEPENDENTES, RENDA BRUTO (R\$), NOTA DE SATISF...
1	Categóricas	4	[REGIÃO, SEXO, ESTADO CIVIL, CATEGORIA SATISFA...

Normalização, mapeamento e discretização concluídos com sucesso.

```
X_train_cls_prepared: (153800, 32)
X_validation_cls_prepared: (153800, 32)
X_test_cls_prepared: (153800, 32)
```

Atividade A3.2 (2º Passo) - ETL: Separar Entrada (X) da Saída (y)

	Dataset	Linhas X	Colunas X	Linhas y	Variável Alvo
0	TRAIN	153800	32	153800	TIPO DA CONTA
1	VALIDATION	153800	32	153800	TIPO DA CONTA
2	TEST	153800	32	153800	TIPO DA CONTA

A3.2 - VALIDAÇÃO FINAL DA SEPARAÇÃO ENTRE X E y

Status: validação concluída com sucesso.

Interpretação: as matrizes de entrada (X) e os vetores de saída (y) possuem dimensões compatíveis nos três conjuntos analisados.

Assim, os datasets TRAIN, VALIDATION e TEST estão consistentes para a próxima etapa de criação e treinamento dos modelos de Classificação.

Atividade A3.3 (3º Passo): Escolher / Criar o Modelo: Classifiers

Escolher enter os seguintes - **Classifiers**:

1. Nearest Neighbors
2. Linear SVM
3. RBF SVM
4. Gaussian Process
5. Decision Tree
6. Random Forest
7. Neural Net
8. AdaBoost
9. Naive Bayes
10. QDA

Qual obteve o maior SCORE ?

INÍCIO DO TREINAMENTO DOS MODELOS DE CLASSIFICAÇÃO

Treinando modelo: Nearest Neighbors
Status: Nearest Neighbors treinado com sucesso.

Treinando modelo: Linear SVM
Status: Linear SVM treinado com sucesso.

Treinando modelo: Decision Tree
Status: Decision Tree treinado com sucesso.

Treinando modelo: Random Forest
Status: Random Forest treinado com sucesso.

Treinando modelo: AdaBoost
Status: AdaBoost treinado com sucesso.

Treinando modelo: Naive Bayes
Status: Naive Bayes treinado com sucesso.

Treinando modelo: QDA
Status: QDA treinado com sucesso.

Treinando modelo: Logistic Regression
Status: Logistic Regression treinado com sucesso.

Todos os modelos de Classificação foram criados e treinados com sucesso.
Total de modelos treinados: 8

	Modelo	Accuracy	Precision Macro	Recall Macro	F1 Macro
0	Random Forest	0.9223	0.9264	0.9224	0.9232
1	AdaBoost	0.8942	0.8974	0.8945	0.8950
2	Logistic Regression	0.8930	0.8935	0.8933	0.8930
3	Linear SVM	0.8930	0.8931	0.8934	0.8929
4	Decision Tree	0.8927	0.8933	0.8929	0.8931
5	Nearest Neighbors	0.7396	0.7440	0.7399	0.7398
6	Naive Bayes	0.5972	0.5706	0.6003	0.5197
7	QDA	0.5244	0.5317	0.5272	0.4501

SELEÇÃO DO MODELO CLASSIFICADOR

Melhor modelo na validação: Random Forest
Accuracy na validação: 0.9223
F1 Macro na validação: 0.9232

Interpretação: o modelo selecionado apresentou o maior score no conjunto de validação e será utilizado nas próximas etapas de avaliação estatística e teste final.

	Modelo Final	Accuracy	Precision Macro	Recall Macro	F1 Macro
0	Random Forest	0.9218	0.9260	0.9219	0.9228

AVALIAÇÃO FINAL DO MODELO CLASSIFICADOR

Modelo final avaliado: Random Forest
Accuracy no teste: 0.9218
F1 Macro no teste: 0.9228

Interpretação: o conjunto de teste foi utilizado apenas após a seleção do melhor modelo na validação, preservando seu papel como avaliação final da capacidade de generalização do classificador.

A3.3.1: Intervalo de confiança: Train

A3.3.1 - INTERVALO DE CONFIANÇA: TRAIN

Modelo avaliado: Random Forest
Método: Validação Cruzada K-Fold com 5 folds
Métrica avaliada: Accuracy

	Modelo	Folds	Accuracy Médio	Desvio Padrão	Erro Padrão	IC 95% Inferior	IC 95% Superior
0	Random Forest	5	0.9053	0.0018	0.0008	0.9031	0.9076

	Fold	Accuracy
0	1	0.9085
1	2	0.9051
2	3	0.9050
3	4	0.9041
4	5	0.9040

RELATÓRIO ESTATÍSTICO - TRAIN

Modelo avaliado: Random Forest
Accuracy médio na validação cruzada: 0.9053
Desvio padrão dos scores: 0.0018
Erro padrão da média: 0.0008
Intervalo de Confiança 95%: [0.9031, 0.9076]
Amplitude do IC 95%: 0.0045

Interpretação:
A validação cruzada no conjunto de treinamento indica a estabilidade interna do modelo final selecionado. O intervalo de confiança de 95% permite avaliar a variação esperada da Accuracy quando o classificador é treinado e validado em diferentes partições do conjunto TRAIN.

Conclusão: a amplitude do intervalo de confiança é baixa, sugerindo desempenho estável entre os folds e boa consistência interna do modelo.


A3.3.2: Intervalo de confiança: Validation

A3.3.2 - INTERVALO DE CONFIANÇA: VALIDATION

Modelo avaliado: Random Forest
Método: Bootstrap sobre o conjunto de validação
Métrica avaliada: Accuracy

Accuracy observado no conjunto de validação: 0.9223

	Modelo	Bootstrap	Accuracy Observado	Accuracy Médio Bootstrap	Desvio Padrão	Erro Padrão	IC 95% Inferior	IC 95% Superior
0	Random Forest	1000	0.9223	0.9223	0.0007	0.0000	0.9211	0.9236



RELATÓRIO ESTATÍSTICO - VALIDATION

Modelo avaliado: Random Forest
Accuracy observado na validação: 0.9223
Accuracy médio bootstrap: 0.9223
Desvio padrão bootstrap: 0.0007
Erro padrão bootstrap: 0.0000
Intervalo de Confiança 95%: [0.9211, 0.9236]
Amplitude do IC 95%: 0.0026


Interpretação:

A análise bootstrap no conjunto de validação avalia a estabilidade do desempenho do modelo final em dados não utilizados no treinamento direto. O intervalo de confiança obtido representa a faixa esperada para a Accuracy considerando reamostragens sucessivas do conjunto VALIDATION.

Conclusão: o intervalo de confiança é estreito, indicando desempenho estável do classificador no conjunto de validação.

	Dataset	Grupo	Observações	Accuracy	Precision	Recall	F1-Score
0	VALIDATION	ESSENTIAL	50400	0.9313	1.0000	0.9313	0.9644
1	VALIDATION	PRIME	51700	0.9466	1.0000	0.9466	0.9726
2	VALIDATION	VIP	51700	0.8893	1.0000	0.8893	0.9414

	Dataset	Grupo	Observações	Accuracy Observado	Accuracy Médio Bootstrap	Desvio Padrão	Erro Padrão	IC 95% Inferior	IC 95% Superior
0	VALIDATION	ESSENTIAL	50400	0.9313	0.9313	0.0011	0.0000	0.9292	0.9335
1	VALIDATION	PRIME	51700	0.9466	0.9466	0.0010	0.0000	0.9447	0.9487
2	VALIDATION	VIP	51700	0.8893	0.8893	0.0014	0.0000	0.8865	0.8921



BOOTSTRAP ESTRATIFICADO DA ACCURACY - VALIDATION

PRIME: Accuracy observado = 0.9466 | IC 95% = [0.9447, 0.9487] | Amplitude = 0.0040
 ESSENTIAL: Accuracy observado = 0.9313 | IC 95% = [0.9292, 0.9335] | Amplitude = 0.0042
 VIP: Accuracy observado = 0.8893 | IC 95% = [0.8865, 0.8921] | Amplitude = 0.0056

Interpretação:
 O grupo com maior desempenho no conjunto de validação foi PRIME, enquanto o menor desempenho foi observado em VIP. Essa leitura estratificada é importante porque a Parte 1 demonstrou diferenças estatísticas relevantes entre ESSENTIAL, PRIME e VIP.

Atividade A3.4 (4º Passo): Medir a acurácia (score) dos Modelos de Classificação:

Atividade A3.4.1: Medir a acurácia (score) - Matriz de Confusão: Conjunto TRAIN

	Previsto ESSENTIAL	Previsto PRIME	Previsto VIP
Real ESSENTIAL	50400	0	0
Real PRIME	1	51698	1
Real VIP	0	0	51700


A3.4.1 - MATRIZ DE CONFUSÃO: TRAIN

Modelo avaliado: Random Forest

Accuracy no TRAIN: 1.0000

Relatório de classificação - TRAIN:

	precision	recall	f1-score	support
ESSENTIAL	1.00	1.00	1.00	50400
PRIME	1.00	1.00	1.00	51700
VIP	1.00	1.00	1.00	51700
accuracy			1.00	153800
macro avg	1.00	1.00	1.00	153800
weighted avg	1.00	1.00	1.00	153800



Atividade A3.4.2: Medir a acurácia (score) - Matriz de Confusão: Conjunto
VALIDATION


	Previsto ESSENTIAL	Previsto PRIME	Previsto VIP
Real ESSENTIAL	46938	2484	978
Real PRIME	318	48938	2444
Real VIP	221	5503	45976

A3.4.2 - MATRIZ DE CONFUSÃO: VALIDATION

Modelo avaliado: Random Forest
Accuracy no VALIDATION: 0.9223

Relatório de classificação - VALIDATION:

	precision	recall	f1-score	support
ESSENTIAL	0.99	0.93	0.96	50400
PRIME	0.86	0.95	0.90	51700
VIP	0.93	0.89	0.91	51700
accuracy			0.92	153800
macro avg	0.93	0.92	0.92	153800
weighted avg	0.93	0.92	0.92	153800



Atividade A3.4.3: Medir a acurácia (score) - Matriz de Confusão: Conjunto TEST

	Previsto ESSENTIAL	Previsto PRIME	Previsto VIP
Real ESSENTIAL	46871	2537	992
Real PRIME	272	48942	2486
Real VIP	239	5494	45967


A3.4.3 - MATRIZ DE CONFUSÃO: TEST

Modelo avaliado: Random Forest

Accuracy no TEST: 0.9218

Relatório de classificação - TEST:

	precision	recall	f1-score	support
ESSENTIAL	0.99	0.93	0.96	50400
PRIME	0.86	0.95	0.90	51700
VIP	0.93	0.89	0.91	51700
accuracy			0.92	153800
macro avg	0.93	0.92	0.92	153800
weighted avg	0.93	0.92	0.92	153800



Atividade A3.5 (5º Passo): Testar o Modelo: Dados da População: amostra aleatória (Sample).

A3.5 - TESTE DO MODELO DE CLASSIFICAÇÃO COM AMOSTRA DO TEST

Base utilizada: conjunto TEST, composto por amostras que não participaram das etapas de treinamento e validação.

Base utilizada para amostragem: 153800 registros e 23 colunas.

	NOTA FISCAL	REGIÃO	SEXO	ESTADO CIVIL	DEPENDENTES	REND BRUTO (R\$)	OPINIÃO DO CLIENTE	I SAT
0	3642214	SUDESTE	FEMININO	DESQUITADO(A) / VIÚVO(A)	0	3,160.9500	Gostei do atendimento prestado pela UVVine	
1	1220021	SUL	MASCULINO	CASADO	0	3,276.2700	Serviço eficiente, recomendo o clube: UVVine	
2	2297905	CENTRO-OESTE	MASCULINO	CASADO	1	3,081.1500	Funcionou bem e me atendeu no prazo certo a UV...	
3	6510602	SUDESTE	FEMININO	CASADO	0	3,422.5100	Gostei do atendimento prestado pela UVVine	
4	1997021	SUDESTE	FEMININO	CASADO	1	3,367.7200	Tive uma experiência ruim com a UVVine	
5	6198358	SUDESTE	MASCULINO	SOLTEIRO	2	22,165.7100	Fiquei satisfeito com o serviço da UVVine	
6	8477066	SUDESTE	MASCULINO	SOLTEIRO	2	26,810.1100	Foi indiferente minha experiência com a UVVine	
7	4158878	SUDESTE	FEMININO	SOLTEIRO	4	27,564.4200	Gostei do atendimento prestado pela UVVine	
8	2077618	CENTRO-OESTE	MASCULINO	CASADO	1	23,464.9100	Funcionou bem e me atendeu no prazo certo a UV...	
9	6137022	SUDESTE	MASCULINO	CASADO	1	27,703.7000	Fiquei satisfeito com o serviço da UVVine	

	NOTA FISCAL	REGIÃO	SEXO	ESTADO CIVIL	DEPENDENTES	REND BRUTO (R\$)	OPINIÃO DO CLIENTE	I SAT
10	3241943	NORTE	MASCULINO	CASADO	0	8,000.3800	Foi indiferente minha experiência com a UVVine	
11	3403191	SUDESTE	FEMININO	CASADO	0	7,476.7000	Foi indiferente minha experiência com a UVVine	
12	8411626	CENTRO-OESTE	FEMININO	SOLTEIRO	3	7,840.6100	Experiência regular, não atendeu a política de...	
13	1261588	SUDESTE	MASCULINO	SOLTEIRO	0	7,861.5400	Razoável, com margem de melhora no preço médio...	
14	8034378	SUDESTE	MASCULINO	SOLTEIRO	1	7,834.7600	Não tenho muito a dizer sobre a UVVine	

Amostra aleatória estratificada selecionada com sucesso.

Total de registros da amostra: 15

Amostra preparada para aplicação do modelo de classificação.

Dimensão da matriz X_sample_cls_array: (15, 32)

	NOTA FISCAL	CLASSE REAL	CLASSE PREVISTA	ACERTO	REGIÃO	SEXO	ESTADO CIVIL	RENDA BRUTO (R\$)
0	3642214	ESSENTIAL	ESSENTIAL	True	SUDESTE	FEMININO	DESQUITADO(A) / VIÚVO(A)	3,160.9500
1	1220021	ESSENTIAL	ESSENTIAL	True	SUL	MASCULINO	CASADO	3,276.2700
2	2297905	ESSENTIAL	ESSENTIAL	True	CENTRO-OESTE	MASCULINO	CASADO	3,081.1500
3	6510602	ESSENTIAL	ESSENTIAL	True	SUDESTE	FEMININO	CASADO	3,422.5100
4	1997021	ESSENTIAL	ESSENTIAL	True	SUDESTE	FEMININO	CASADO	3,367.7200
5	6198358	PRIME	PRIME	True	SUDESTE	MASCULINO	SOLTEIRO	22,165.7100
6	8477066	PRIME	PRIME	True	SUDESTE	MASCULINO	SOLTEIRO	26,810.1100
7	4158878	PRIME	PRIME	True	SUDESTE	FEMININO	SOLTEIRO	27,564.4200
8	2077618	PRIME	PRIME	True	CENTRO-OESTE	MASCULINO	CASADO	23,464.9100
9	6137022	PRIME	PRIME	True	SUDESTE	MASCULINO	CASADO	27,703.7000
10	3241943	VIP	VIP	True	NORTE	MASCULINO	CASADO	8,000.3800
11	3403191	VIP	VIP	True	SUDESTE	FEMININO	CASADO	7,476.7000
12	8411626	VIP	VIP	True	CENTRO-OESTE	FEMININO	SOLTEIRO	7,840.6100
13	1261588	VIP	VIP	True	SUDESTE	MASCULINO	SOLTEIRO	7,861.5400
14	8034378	VIP	VIP	True	SUDESTE	MASCULINO	SOLTEIRO	7,834.7600

A3.5 - RESULTADO DA AMOSTRA ALEATÓRIA - TEST

Accuracy na amostra do TEST: 1.0000

Interpretação: o modelo foi aplicado em uma amostra aleatória estratificada do conjunto TEST. A comparação entre CLASSE REAL e CLASSE PREVISTA permite verificar, em registros individuais não utilizados nas etapas de treinamento e validação, se o classificador mantém coerência preditiva.

RELATÓRIO PARCIAL - MODELO DE CLASSIFICAÇÃO

RELATÓRIO PARCIAL - MODELO DE CLASSIFICAÇÃO

1. Introdução

Este relatório apresenta os resultados do modelo de Classificação desenvolvido para o projeto UWine. O objetivo desta etapa foi construir um classificador capaz de prever automaticamente o TIPO DA CONTA do cliente, classificado em ESSENTIAL, PRIME ou VIP, a partir das variáveis disponíveis na base.

2. Metodologia e Modelagem

Foram avaliados diferentes algoritmos de classificação, incluindo Nearest Neighbors, Decision Tree, Random Forest, AdaBoost, Naive Bayes, QDA, Regressão Logística e Linear SVM. O modelo com melhor desempenho no conjunto de validação foi o Random Forest Classifier.

Os conjuntos TRAIN, VALIDATION e TEST mantiveram a estratégia metodológica definida na Parte 1 do projeto, com amostragem estratificada por TIPO DA CONTA. Cada conjunto possui 153.800 registros, distribuídos entre ESSENTIAL, PRIME e VIP conforme os tamanhos amostrais ideais previamente definidos.

3. Desempenho Geral do Modelo

O modelo apresentou desempenho elevado e consistente nos conjuntos analisados:

- Accuracy no TRAIN: 100,00%;
- Accuracy no VALIDATION: 92,23%;
- Accuracy no TEST: 92,18%.

A proximidade entre os resultados de validação e teste indica boa capacidade de generalização. Embora o resultado no treino seja de 100%, a avaliação em validação e teste mostra que o modelo mantém desempenho alto em dados não utilizados diretamente no ajuste final.

4. Estabilidade Estatística

A estabilidade do classificador foi avaliada por meio de validação cruzada no conjunto de treino e bootstrap no conjunto de validação. Na validação cruzada, o modelo apresentou Accuracy média de 0,9053, com intervalo de confiança de 95% entre 0,9031 e 0,9076. A baixa amplitude do intervalo indica estabilidade entre diferentes partições do conjunto TRAIN.

Essa etapa reforça que o desempenho observado não depende apenas de uma divisão específica dos dados, mas se mantém consistente em diferentes reamostragens.

5. Análise por Segmento

A análise por matriz de confusão e métricas por classe permitiu avaliar o comportamento do classificador separadamente para ESSENTIAL, PRIME e VIP. Essa leitura estratificada é importante porque a Parte 1 demonstrou diferenças estatísticas relevantes entre os grupos.

De forma geral, o modelo apresentou bom desempenho na identificação das três categorias, com maior facilidade para algumas classes e maior dispersão em outras. Esse comportamento indica que

os grupos possuem características preditivas relevantes, mas também apresentam regiões de sobreposição, especialmente quando clientes de segmentos distintos compartilham padrões semelhantes de renda, consumo ou satisfação.

6. Teste com Amostra Aleatória do Conjunto TEST

O modelo também foi aplicado a uma amostra aleatória estratificada retirada do conjunto **TEST**, composto por registros que não participaram das etapas de treinamento e validação.

Nessa amostra, o classificador apresentou acerto integral, comparando a classe real com a classe prevista.

Esse resultado deve ser interpretado como uma verificação pontual de coerência da aplicação do modelo, e não como substituto das métricas obtidas nos conjuntos completos de validação e teste.

7. Conclusões Gerenciais

O modelo **Random Forest Classifier** apresentou alta capacidade de classificação automática dos clientes nos segmentos **ESSENTIAL**, **PRIME** e **VIP**.

A acurácia superior a 92% nos conjuntos de validação e teste indica que as variáveis disponíveis na base possuem forte poder explicativo para diferenciar os tipos de conta.

A aplicação do modelo pode apoiar processos de segmentação, personalização de campanhas e priorização de ações comerciais, desde que acompanhada de monitoramento periódico e revalidação com novos dados.

- **Alta Confiabilidade:** O modelo Random Forest alcançou mais de 92% de acurácia média nos conjuntos de teste, garantindo segurança na classificação automatizada de clientes.
- **Estabilidade Populacional:** A validação via Bootstrap e testes em amostras aleatórias confirmaram que o modelo mantém sua performance independente da variação dos dados de entrada.
- **Eficiência Operacional:** A identificação automática dos segmentos **ESSENTIAL**, **PRIME** e **VIP** permite a personalização imediata do atendimento e ofertas, otimizando a experiência do cliente.

RELATÓRIO FINAL - VISÃO HOLÍSTICA SOBRE O PROJETO

RELATÓRIO FINAL - VISÃO HOLÍSTICA SOBRE O PROJETO UWINE

O projeto aplicou três abordagens complementares de Machine Learning sobre a base UWine: Regressão, Clusterização e Classificação. Em conjunto, esses modelos permitiram estimar valores monetários, identificar agrupamentos comportamentais e automatizar a previsão do tipo de conta.

Na Regressão, o modelo `Extra Trees Regressor` foi adotado como modelo final para estimar `TOTAL (R$)`. O modelo alcançou R^2 de 0,7524 no conjunto `TEST`, superando o resultado anterior do `Random Forest Regressor`, que havia obtido R^2 de 0,7017. Esse avanço indica melhora relevante na capacidade explicativa do modelo para previsão de valores monetários.

Na Clusterização, o modelo `KMeans` foi utilizado para identificar agrupamentos naturais sem utilizar `TIPO DA CONTA` no treinamento. A rediscretização supervisionada mostrou casamento parcial entre clusters e tipos reais, com taxa estável em torno de 60,3% nos conjuntos `TRAIN`, `VALIDATION` e `TEST`. Assim, os clusters devem ser interpretados como agrupamentos comportamentais, e não como substitutos diretos da segmentação oficial.

Na Classificação, o modelo `Random Forest Classifier` apresentou o melhor desempenho para prever `TIPO DA CONTA`, com Accuracy de 92,18% no conjunto `TEST`. Esse resultado indica forte potencial para apoiar processos de categorização automática e personalização de estratégias por segmento.

De forma integrada, os resultados confirmam que os segmentos `ESSENTIAL`, `PRIME` e `VIP` apresentam comportamentos estatísticos distintos, justificando a abordagem estratificada adotada desde a Parte 1. A solução construída oferece uma visão mais ampla do cliente, combinando previsão de valor, agrupamento comportamental e classificação automática de perfil.

- **Visão 360° do Cliente:** Conseguimos prever quanto o cliente gastará, a qual grupo ele pertence naturalmente e automatizar sua categoria oficial com mais de 92% de precisão.
- **Estabilidade Sistêmica:** Todos os modelos foram validados via Bootstrap e K-Fold, garantindo que a inteligência gerada seja aplicada de forma segura em toda a base de 461.400 registros.
- **Potencial de Monetização:** A integração desses modelos permite uma redução drástica no custo de aquisição e um aumento no Life Time Value (LTV) através de campanhas hiper-personalizadas por segmento.

```
[NbConvertApp] Converting notebook /content/LNONMERLO_TCC_PARTE_2_V4.ipynb to html
[NbConvertApp] WARNING | Alternative text is missing on 18 image(s).
[NbConvertApp] Writing 3231137 bytes to /content/LNONMERLO_TCC_PARTE_2_V4.html
```